

Modelos generativos, modelos nulos y comparación contrafactual

¿Estructura social relevante o producto del azar?

Una métrica observada sólo adquiere sentido contra un mundo contrafactual - lo que habría producido otro proceso de formación de redes.

Pregunta de la sesión

¿Cómo sabemos si las conexiones y métricas observadas en una red expresan una estructura social relevante o si, en cambio, podrían ser producto del azar?

Para responderla necesitamos modelos nulos, modelos generativos, distribuciones simuladas y comparación contrafactual.

| ¿Estructura social relevante o azar? Toda la sesión gira en torno a esta pregunta.

El problema inferencial

Una red observada siempre combina:

$$G_{obs} = \textit{estructura social} + \textit{azar} + \textit{proceso de medición}$$

La pregunta central es

$T(G_{obs})$ es excepcional respecto de ¿qué mundo contrafactual?

donde $T(G)$ es una métrica de red.

Comparar una red exige imaginar otras redes posibles

No basta calcular una métrica.

Necesitamos preguntar

¿Qué valores de esta métrica serían esperables si la red se hubiera generado bajo otro proceso?

Ese otro proceso puede representarse mediante

- un modelo nulo;
- un modelo generativo;
- una distribución simulada;
- una comparación contrafactual.

Interpretar una métrica implica imaginar la distribución de valores que otro proceso habría producido.

Modelos nulos

Un modelo nulo define qué parte de la estructura queremos tratar como esperable o irrelevante.

Ejemplo

$$H_0: G_{obs} \sim M_0$$

donde M_0 es un proceso generador de redes bajo una hipótesis nula.

El modelo nulo no es “la ausencia de teoría”.

Es una **teoría mínima** sobre qué estructura habría si el mecanismo sustantivo de interés no estuviera operando.

Elegir un modelo nulo es, por tanto, una decisión teórica y no un trámite estadístico.

Modelos generativos

Un modelo generativo especifica un proceso capaz de producir redes.

Formalmente

$$P(G \mid \theta)$$

donde G es una red posible, θ son parámetros del modelo y $P(G \mid \theta)$ es la probabilidad de observar esa red bajo el modelo.

La pregunta cambia de

¿Qué métrica tiene la red?



¿Qué proceso podría haber producido una red con estas propiedades?

Modelos nulos y modelos generativos

Un mismo modelo puede funcionar como modelo generativo o como modelo nulo.

Como modelo generativo

M propone un **mecanismo de formación de red**.

Es una teoría sobre cómo se generan los vínculos.

Como modelo nulo

M_0 define el **mundo contrafactual** contra el cual evaluamos una propiedad observada.

Es un punto de comparación, no necesariamente una teoría.

Ejemplo

Erdős-Rényi puede ser una **teoría simple de formación aleatoria** o un **punto de comparación** para saber si una red observada es más agrupada de lo esperado.

La elección del modelo nulo depende de la pregunta

Distintas preguntas requieren distintos contrafactuales.

- | | | |
|-----------|--|--|
| 01 | ¿La red tiene más vínculos de los esperados? | una red aleatoria con mismo número de nodos |
| 02 | ¿La transitividad es alta incluso controlando por la secuencia de grados? | un modelo que preserve grados |
| 03 | ¿Hay comunidades más fuertes que las esperadas por azar? | un modelo que represente bloques o pertenencias grupales |

Erdős-Rényi $G(n,p)$

El modelo $G(n,p)$ parte con n nodos. Para cada par de nodos, se crea una arista con probabilidad p .

$$P(A_{ij} = 1) = p$$

$$P(A_{ij} = 0) = 1 - p$$



Cada par decide por separado: la presencia de una arista no influye en las demás.

Probabilidad de una red en $G(n,p)$

En una red no dirigida con n nodos hay $M = \frac{n(n-1)}{2}$ aristas posibles.

Si una red observada tiene m aristas, entonces

$$P(G) = p^m (1 - p)^{M-m}$$

La probabilidad depende sólo de cuántas aristas hay, no de **dónde** están.

Toda la estructura particular de la red es irrelevante bajo este modelo.

Todas las redes con el mismo número de aristas tienen la misma probabilidad.

Número esperado de aristas y grado esperado

Número esperado de aristas

$$E[m] = p \frac{n(n-1)}{2}$$

Grado esperado de un nodo

$$E[k_i] = p (n - 1)$$

Densidad esperada


$$E[D] = p$$

■ En $G(n,p)$, la densidad esperada coincide exactamente con el parámetro p .

Distribución de grados en $G(n,p)$

El grado de un nodo sigue una distribución binomial:

$$k_i \sim \text{Bin}(n - 1, p)$$



Si n es grande y p es pequeño, puede aproximarse mediante una Poisson:

$$P(k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

donde $\lambda = p(n - 1)$ es el grado esperado.

Bajo este modelo, los grados se concentran cerca de su promedio.

No hay nodos con grados extremadamente distintos al resto.

Un único parámetro -el grado esperado- describe toda la distribución de grados.

Modelo $G(n,m)$

El modelo $G(n,m)$ fija n (el número de nodos) y m (el número exacto de aristas), y luego selecciona al azar una red entre todas las redes posibles con n nodos y m aristas.

Si hay M aristas posibles

$$M = \frac{n(n-1)}{2}$$

el número de redes posibles con m aristas es

$$\binom{M}{m}$$


A diferencia de $G(n,p)$, aquí el número de aristas no es aleatorio.

Está fijo por diseño: sólo varía dónde se ubican las aristas.

Random Graph Model:

Erdős-Renyi-Gilbert proponen $G(n,p)$, donde p es la probabilidad de existencia de cada m .

Ejemplo: Redes creadas en R todas con 5 nodos y cada link con probabilidad 0,05.



Por lo tanto $G(n,p)$ no es exactamente lo mismo que $G(n,m)$, pero el primero se asemeja al segundo para grandes n

$G(n,p)$ y $G(n,m)$

$G(n,p)$

El número de aristas es **aleatorio**.

$$m \sim \text{Bin}(M, p)$$

$G(n,m)$

El número de aristas está **fijo**.

$$m = \text{constante}$$

Ambos modelos son **similares cuando n es grande**, pero responden a preguntas distintas.

Componente gigante


En redes aleatorias aparece una transición importante. Sea $\lambda = E[k]$ el grado promedio.

Si $\lambda < 1$

la red tiende a estar **fragmentada**.

Si $\lambda > 1$

tiende a emerger un **componente gigante**.



Cerca de $\lambda = 1$ la red pasa de estar fragmentada a tener un componente gigante.

Percolación → emerge un componente gigante. Sea S la fracción del grafo ocupado por el componente gigante

$$S = 1 - e^{-\lambda S}$$

Proporción no
conectada al
componente
gigante

Si $\lambda < 1$, $S = 0$

Si $\lambda \geq 1$, $S > 0$

No linealidad
Transición de fase




Fig. 4.1 The mean component size (solid line), excluding the giant component if there is one, and the giant component size (dotted line), for the Poisson random graph, (4.3) and (4.4).

Transición de fase

Una pequeña variación en el grado promedio puede cambiar cualitativamente la estructura global.

$\lambda < 1 \rightarrow$ **islas** — componentes pequeños y desconectados

$\lambda > 1 \rightarrow$ **componente gigante** que conecta gran parte de la red

Esta es una intuición central para conectar **redes y complejidad**.

Si la red mundial fuese aleatoria: ¿Cuántas personas debería uno conocer para que $d < 6$ a nivel mundial?

$$k^d = N$$

Cada nodo tiene k links. Por ende, en una red aleatoria probabilísticamente existen k^d nodos a una distancia d .

Si la red mundial fuese aleatoria: ¿Cuántas personas debería uno conocer para que $d < 6$ a nivel mundial?

$$k^d = N$$

$$d = \log N / \log k$$

Si la red mundial fuese aleatoria: ¿Cuántas personas debería uno conocer para que $d < 6$ a nivel mundial?

$$k^d = N$$

$$d = \log N / \log k$$

$$6 = \log 8\,000\,000\,000 / \log k$$

$$k \approx 45 \text{ pers.}$$


Ejemplo 1


¿Cuántos intermediarios son necesarios para enviar una carta desde la persona A a la persona B a través de conocidos? Milgram (1967)

Experimento:


Inicio: Nebraska/Kansas,
Destino: Boston

“Si no conoce al destinatario personalmente no trate de contactarlo, sino envíe la carta a una persona que usted conoce y que, a su juicio, tiene más probabilidades de conocerlo”





Ejemplos de lo que pasó




Stanley Milgram, 1967

Promedio de intermediarios: 6



Ejemplo 2

Paul Erdős, matemático. Publicó 1500 artículos. La gran mayoría coautorados



Ron Graham (alias Tom Oda).

Figure 1

To appear in Topics in Graph Theory (V. Harary, ed.) New York Academy of Sciences (1979).

Algunos ejemplos de números de Erdős de grandes físicos

Albert Einstein	1921	2
Niels Bohr	1922	5
Erwin Schrödinger	1933	8
Enrico Fermi	1938	3
Richard P. Feynman	1965	4
Murray Gell-Mann	1969	3
Norman F. Ramsey	1989	3



Número de Erdős

Número de Erdős 0 --- 1 persona

Número de Erdős 1 --- 504 personas

Número de Erdős 2 --- 6593 personas

Número de Erdős 3 --- 33605 personas

Número de Erdős 4 --- 83642 personas

Número de Erdős 5 --- 87760 personas

Número de Erdős 6 --- 40014 personas

Número de Erdős 7 --- 11591 personas

Número de Erdős 8 --- 3146 personas


Número de Erdős 9 --- 819 personas

Número de Erdős 10 --- 244 personas


Número de Erdős 11 --- 68 personas

Número de Erdős 12 --- 23 personas

Número de Erdős 13 --- 5 personas






Mediana = 5; Promedio = 4.69, Desviación = 1.27



Mediana = 5; Promedio = 4.69, Desviación = 1.27

Ejemplo 3


El oráculo de Kevin Bacon
<http://oracleofbacon.org/>




¿Es Kevin Bacon el actor con más conexiones?

Ranking	Nombre	Distancia promedio	# of películas	# of co-actores
1	Rod Steiger	2.537527	112	2562
2	Donald Pleasence	2.542376	180	2874
3	Martin Sheen	2.551210	136	3501
4	Christopher Lee	2.552497	201	2993
5	Robert Mitchum	2.557181	136	2905
6	Charlton Heston	2.566284	104	2552
7	Eddie Albert	2.567036	112	3333
8	Robert Vaughn	2.570193	126	2761
9	Donald Sutherland	2.577880	107	2865
10	John Gielgud	2.578980	122	2942
11	Anthony Quinn	2.579750	146	2978
12	James Earl Jones	2.584440	112	3787
...				
876	Kevin Bacon	2.786981	46	1811
...				


PRIMERAS PROPIEDADES EMERGENTES



Milgram



Erdős



Bacon


En todos los ejemplos aparece el fenómeno de mundos pequeños

Mundos pequeños

Una red presenta propiedades de mundo pequeño cuando combina:

01 distancias promedio cortas

02 alto clustering local



La distancia promedio puede crecer lentamente con el tamaño de la red.

En muchas redes aleatorias

$$\ell \sim \frac{\log n}{\log \lambda}$$

donde ℓ es la distancia promedio.

La distancia promedio crece de forma **logarítmica** con el tamaño de la red: muy lentamente.

Distancias cortas y alto clustering local pueden coexistir en una misma red.

El problema de los mundos pequeños

Las redes aleatorias pueden producir distancias cortas.

Pero suelen subestimar el clustering observado en redes reales.

Por tanto, la pregunta es

¿Cómo puede una red tener simultáneamente **alta cohesión local** y **distancias globales cortas**?

Modelo de Watts-Strogatz


El modelo parte de una **red regular**. Luego, algunas aristas se reconectan aleatoriamente con probabilidad β .



Valores intermedios de β pueden producir redes small-world.

Modelo de Watts-Strogatz



El modelo parte de una **red regular**. Luego, algunas aristas se reconectan aleatoriamente con probabilidad β .




Fuente: Watts y Strongatz (1998)

Valores intermedios de β pueden producir redes small-world.

Watts-Strogatz Model



$C(p)$: clustering coef
 $D(p)$: Distancia promedio



Clustering y distancia en Watts-Strogatz

El modelo muestra que unos pocos vínculos de largo alcance pueden reducir fuertemente la distancia promedio sin destruir completamente el clustering.

$$\beta \uparrow \Rightarrow \ell \downarrow$$

al aumentar la reconexión, la distancia promedio se reduce

$$\beta \text{ moderado} \Rightarrow C \text{ alto}$$

el clustering puede permanecer alto para valores moderados de β

Homofilia y lazos débiles

Una intuición sociológica del mundo pequeño combina dos mecanismos:

Homofilia

Los actores tienden a conectarse con otros similares o próximos.

Produce clustering.

Lazos débiles

Algunos vínculos conectan círculos sociales distintos.

Reducen distancias globales.

cierre local + puentes globales → mundo pequeño

¿Por qué no basta Erdős-Rényi y Watts-Strogatz?

Erdős-Rényi supone que **todos los nodos tienen la misma probabilidad de recibir vínculos**.


Pero muchas redes reales tienen fuertes diferencias de grado:

- | algunos actores tienen muy pocos vínculos;
- | algunos actores concentran muchos vínculos.


Si queremos evaluar clustering, comunidades o brokerage, puede ser necesario **controlar primero por la secuencia de grados**.

| **Antes de interpretar clustering o comunidades, hay que controlar por la secuencia de grados.**

El problema con los hubs persiste.



Watts-Strogatz Model



hubs

Modelo de configuración

El modelo de configuración genera redes aleatorias que **preservan la secuencia de grados observada**.

Sea la secuencia de grados

$$k = (k_1, k_2, \dots, k_n)$$

El modelo genera redes aleatorias tales que

$$k_i^{sim} = k_i^{obs}$$

para todo nodo i , o aproximadamente según la implementación.

Cada nodo conserva exactamente su número de vínculos.

Lo que se aleatoriza es **a quién** se conecta.

Intuición del modelo de configuración

- 01 Cada nodo recibe k_i “**stubs**” o medios vínculos.

- 02 Luego los stubs se emparejan aleatoriamente.

- 03 Así se conserva **cuántos** vínculos tiene cada nodo, pero se aleatoriza **con quién** está conectado.

El contrafactual es

¿Qué estructura esperaríamos si los actores mantuvieran su grado, pero sus vecinos fueran aleatorios?

| Mismo grado, vecinos aleatorios: ese es el mundo contrafactual del modelo.

Uso sustantivo del modelo de configuración

El modelo de configuración sirve para evaluar si una propiedad observada **excede lo esperable dada la distribución de grados**.

Ejemplos

- | clustering
- | modularidad
- | assortativity
- | centralización
- | frecuencia de triángulos
- | tamaño del componente gigante


Pregunta típica

$$T(G_{obs}) > T(G_{sim})$$


¿por cuánto y con qué frecuencia?


- | La distribución de grados se controla antes de interpretar cualquier otra propiedad.

Pero volvamos sobre el problema de los hubs:
Problema → Suelen ser más probables de lo que predicen los modelos anteriores



Watts-Strogatz Model





Emergence of Scaling in Random Networks

Albert-László Barabási* and Réka Albert

www.sciencemag.org SCIENCE VOL 286 15 OCTOBER 1999



Albert-László Barabási

Northeastern University, Harvard Medical School, Central European University

Verified email at neu.edu - [Homepage](#)

[network science](#) [statistical physics](#) [biological physics](#) [physics](#) [medicine](#)

[FOLLOW](#)

TITLE

CITED BY

YEAR

Emergence of scaling in random networks

AL Barabási, R Albert

Science 286 (5439), 509-512

51548

1999



Preferential attachment

El modelo de preferential attachment parte de una idea simple:

los nodos nuevos tienen mayor probabilidad de conectarse con nodos que ya tienen muchas conexiones.

Formalmente

$$P(i) = \frac{k_i}{\sum_j k_j}$$

donde k_i es el grado del nodo i .

La probabilidad de recibir el próximo vínculo es **proporcional al grado actual** del nodo.

El mecanismo “rich get richer”

Si un nodo tiene muchas conexiones, tiene mayor probabilidad de recibir nuevas conexiones.




Eso aumenta su grado.



Luego, al tener mayor grado, aumenta **nuevamente** su probabilidad de recibir conexiones futuras.

$$k_i \uparrow \Rightarrow P(i) \uparrow \Rightarrow k_i \uparrow$$

Probabilidad de conectarse con un nodo más popular es mayor



Fuente: Barabasi (2002)

Redes scale-free

El preferential attachment puede generar distribuciones de grado con cola pesada.

Una forma típica es

$$P(k) \propto k^{-\gamma}$$

Esto significa que

- | muchos nodos tienen pocos vínculos;
- | pocos nodos concentran muchísimos vínculos.

Una **ley de potencia**: la probabilidad de un grado cae como una potencia de ese grado.

No hay una escala típica de conectividad.

- | La estructura resultante puede ser muy desigual.

Implicancias:

1. Emergen los hubs con mayor probabilidad que bajo un esquema aleatorio
2. El “rico” es cada vez más “rico” (efecto “matthews”)

The Matthew Effect in Science



**The reward and communication systems
of science are considered.**

Robert K. Merton

(Science 1968)

Esta afirmación se ve una y otra vez en los últimos 20-25 años.

“scale-free networks represent
a foundational idea
in network science”

Precaución sobre scale-free networks

- | No toda red con hubs es necesariamente scale-free.
 - | No toda cola pesada proviene de preferential attachment.
 - | No toda red real se ajusta bien a una ley de potencia.
-

El valor del modelo no está en tratarlo como **descripción universal**, sino en entender **qué tipo de mecanismo puede producir concentración estructural**.

Power-Law Distributions in Empirical Data

Authors: Aaron Clauset, Cosma Rohilla Shalizi, and M. E. J. Newman | [AUTHORS INFO & AFFILIATIONS](#)

<https://doi.org/10.1137/070710111>

 GET ACCESS

 BibTeX

 Tools 

Abstract

Power-law distributions occur in many situations of scientific interest and have significant consequences for our understanding of natural and man-made phenomena. Unfortunately, the detection and characterization of power laws is complicated by the large fluctuations that occur in the tail of the distribution—the part of the distribution representing large but rare events—and by the difficulty of identifying the range over which power-law behavior holds. Commonly used methods for analyzing power-law data, such as least-squares fitting, can produce substantially inaccurate estimates of parameters for power-law distributions, and even in cases where such methods return accurate answers they are still unsatisfactory because they give no indication of whether the data obey a power law at all. Here we present a principled statistical framework for discerning and quantifying power-law behavior in empirical data. Our approach combines maximum-likelihood fitting methods with goodness-of-fit tests based on the Kolmogorov–Smirnov (KS) statistic and likelihood ratios. We evaluate the effectiveness of the approach with tests on synthetic data and give critical comparisons to previous approaches. We also apply the proposed methods to twenty-four real-world data sets from a range of different disciplines, each of which has been conjectured to follow a power-law distribution. In some cases we find these conjectures to be consistent with the data, while in others the power law is ruled out.

Article | [Open Access](#) | [Published: 04 March 2019](#)

Scale-free networks are rare

[Anna D. Broido](#)  & [Aaron Clauset](#) 

[Nature Communications](#) **10**, Article number: 1017 (2019) | [Cite this article](#)


64k Accesses | **365** Citations | **588** Altmetric | [Metrics](#)

Abstract

Real-world networks are often claimed to be scale free, meaning that the fraction of nodes with degree k follows a power law $k^{-\alpha}$, a pattern with broad implications for the structure and dynamics of complex systems. However, the universality of scale-free networks remains controversial. Here, we organize different definitions of scale-free networks and construct a severe test of their empirical prevalence using state-of-the-art statistical tools applied to nearly 1000 social, biological, technological, transportation, and information networks. Across these networks, we find robust evidence that strongly scale-free structure is empirically rare, while for most networks, log-normal distributions fit the data as well or better than power laws. Furthermore, social networks are at best weakly scale free, while a handful of technological and biological networks appear strongly scale free. These findings highlight the structural diversity of real-world networks and the need for new theoretical explanations of these non-scale-free patterns.

+ sobre preferential attachment


Controversia reciente que pone en duda la universalidad del fenómeno



Fuente: Clauset 2018 at SFI

+ sobre preferential attachment

Y en las redes sociales ninguna pasaría el test (!!)



+ sobre preferential attachment

¿Y qué dice Barabasi?


→ <https://www.barabasilab.com/post/love-is-all-you-need>

“they fail to see the scale-free property because they invent a new criterion of weak and strong scale-free networks”

Barabasi, 6/3/2018

- Las redes reales a menudo no pueden describirse de manera adecuada mediante un único modelo estructural (sea E-R, SW, PA u otra)
- Auge de modelos multicapa o hypergraphs
- Escalas diferentes en la misma red
- Estos modelos generan distribuciones alternativas más flexibles que los modelos scale-free (log-normal, exponencial truncada,...)

A



Delvenne, Yaliraki y Barahona (2010)

Comunidades y bloques

Muchas redes presentan patrones de conexión asociados a grupos latentes o conocidos.

La pregunta es

¿Los nodos se conectan de manera distinta según el grupo al que pertenecen?

Ejemplos

- | partidos políticos
- | escuelas
- | disciplinas

- | organizaciones
- | países
- | comunidades latentes

| Si el grupo importa, el modelo nulo debe incorporar bloques.

Stochastic Block Model

En un Stochastic Block Model, cada nodo pertenece a un bloque.

$$z_i \in \{1, \dots, K\}$$

La probabilidad de vínculo depende de los bloques de origen y destino.

$$P(A_{ij} = 1) = \theta_{z_i z_j}$$

donde θ_{ab} es la probabilidad de conexión entre nodos del bloque a y nodos del bloque b .

Cada par de bloques tiene su propia probabilidad de conexión.

El bloque al que pertenece cada nodo condiciona **con quién** se conecta.

Matriz de probabilidades entre bloques

Para K bloques, el modelo define una matriz:

$$\Theta = \begin{pmatrix} \theta_{11} & \theta_{12} & \cdots & \theta_{1K} \\ \theta_{21} & \theta_{22} & \cdots & \theta_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ \theta_{K1} & \theta_{K2} & \cdots & \theta_{KK} \end{pmatrix}$$

Si

$\theta_{aa} > \theta_{ab}$ para $a \neq b$, hay **estructura comunitaria**.

Cada celda θ_{ab} es la probabilidad de conexión entre el bloque a y el bloque b .

La **diagonal** recoge la densidad interna de cada bloque.

Qué permite estudiar un SBM

El SBM permite representar:

- | comunidades densas
- | bloques equivalentes
- | patrones centro-periferia
- | estructuras multipartitas
- | diferencias entre conexiones intra e intergrupo

La idea central **no es sólo encontrar comunidades.**

| Es modelar probabilidades de conexión condicionadas por pertenencia a bloques.

Degree-Corrected Stochastic Block Model

El SBM básico puede confundir comunidades con diferencias de grado.

El Degree-Corrected SBM incorpora **heterogeneidad de grado dentro de los bloques**.

Una forma general es

$$P(A_{ij} = 1) \propto \omega_{z_i z_j} \phi_i \phi_j$$

$\omega_{z_i z_j}$ captura la conexión **entre bloques**;

ϕ_i y ϕ_j capturan la **propensión individual** a tener vínculos.

Dos factores separados: el **bloque** al que pertenece el nodo y su **propensión individual** a tener vínculos.

El DC-SBM separa la estructura de bloques de la heterogeneidad de grado.

Por qué corregir por grado

Dos nodos pueden tener muchos vínculos porque:

- | pertenecen a un bloque densamente conectado;
- | son nodos de alto grado dentro de cualquier bloque.

El Degree-Corrected SBM **separa parcialmente ambos procesos.**

estructura de bloques $\neq$ heterogeneidad de grado

Distribuciones simuladas

Para evaluar una métrica observada, simulamos muchas redes bajo un modelo nulo.

01 Simular N redes bajo el modelo nulo

$$G_1^{sim}, G_2^{sim}, \dots, G_N^{sim} \sim M_0$$

02 Para cada red simulada, calcular la métrica

$$T(G_r^{sim})$$

| Esto genera una distribución contrafactual de la métrica.

Comparar la red observada

Luego ubicamos la métrica observada dentro de la distribución simulada.

$$T(G_{obs})$$

Si el valor observado cae en una **zona extrema**, la red observada es poco compatible con ese modelo nulo.

La inferencia depende de la pregunta

01 cola derecha

02 cola izquierda

03 dos colas

Valor p empírico

Si usamos una prueba de cola derecha:

$$p_{emp} = \frac{1 + \sum_{r=1}^N \mathbb{I}[T(G_r^{sim}) \geq T(G_{obs})]}{1 + N}$$

donde

- | N es el número de redes simuladas;
- | $\mathbb{I}[\cdot]$ es una función indicadora de cuántas redes simuladas tiene un valor “igual o más” extremo que $T(G_{obs})$;
- | el +1 evita obtener $p = 0$ con simulaciones finitas.

| El valor p empírico cuenta qué fracción de las simulaciones iguala o supera lo observado.

Interpretación del valor p empírico

El valor p empírico responde

Bajo el modelo nulo elegido, ¿con qué frecuencia observaríamos una métrica al menos tan extrema como la observada?

No responde

- | si la hipótesis sustantiva es verdadera;
- | si el modelo nulo es correcto;
- | si la red fue causada por un único mecanismo.

| La conclusión siempre depende del contrafactual elegido.

Ejemplo de comparación

Supongamos

01 Métrica observada

$$T(G_{obs}) = 0.42$$

02 Simulamos
 $N = 1000$ redes bajo un modelo de
configuración

03 En 17 simulaciones

$$T(G_r^{sim}) \geq 0.42$$

Entonces

$$p_{emp} = \frac{1+17}{1+1000}$$
$$= 0.018$$

Qué debe preservar el modelo nulo

Un buen modelo nulo **preserva** aquello que no queremos explicar.

Y **aleatoriza** aquello que sí queremos evaluar.

Ejemplos

$G(n,p)$

preserva n y densidad esperada.

$G(n,m)$

preserva n y número exacto de aristas.

Modelo de configuración

preserva la secuencia de grados.

SBM

preserva estructura de bloques.

Pregunta sustantiva y contrafactual

Pregunta	Modelo nulo razonable
¿La red es más densa que el azar?	$G(n,p)$ o $G(n,m)$
¿Hay más clustering controlando por grado?	Configuración
¿Hay comunidades?	SBM
¿Los hubs explican la estructura?	Degree-Corrected SBM
¿La red combina clustering alto y distancia corta?	Watts-Strogatz o comparación con $G(n,p)$
¿La concentración puede emerger por acumulación?	Preferential attachment

Una misma métrica puede cambiar de interpretación

Supongamos que una red tiene alta transitividad.

Bajo $G(n,p)$ puede parecer **muy excepcional**.

Bajo un modelo de configuración puede ser **menos excepcional** si la secuencia de grados ya induce triángulos.

Bajo un SBM puede deberse a **bloques densamente conectados**.

La métrica no habla sola.

Pregunta de cierre

El análisis de redes no consiste sólo en describir estructuras.

Consiste también en preguntar:

¿Comparado con qué?

Una métrica observada adquiere sentido cuando se interpreta **contra un proceso alternativo de formación de redes.**

Referencias

Erdős, P., & Rényi, A. (1959). "On Random Graphs."

Watts, D. J., & Strogatz, S. H. (1998). "Collective Dynamics of Small-World Networks." *Nature*, 393, 440-442.

Barabási, A.-L., & Albert, R. (1999). "Emergence of Scaling in Random Networks." *Science*, 286(5439), 509-512.
