

Inferencia estadística en redes: QAP, ERGM e interferencia

De la descripción de estructuras a la evaluación de hipótesis sobre vínculos, similitud e influencia.

¿Cómo pasamos de describir una red a evaluar hipótesis sobre vínculos, similitud e influencia?

Hasta ahora hemos descrito estructuras

Podemos observar:

- Quién está conectado con quién;
- Quién ocupa posiciones centrales;
- Dónde aparecen comunidades;
- Cuán densa es la relación entre un grupo;
- Qué actores cumplen roles de intermediación.

Ahora queremos hacer preguntas **inferenciales**:

**¿por qué observamos esos
vínculos y no otros?**

De descripción a inferencia

Supongamos que observamos que actores similares están conectados. Podemos preguntar:

$$P(A_{ij} = 1 \mid X_i = X_j) > P(A_{ij} = 1 \mid X_i \neq X_j)$$

Y a partir de ahí:

- ¿Esa diferencia podría surgir por azar?;
- ¿Cómo tratamos la dependencia entre vínculos?;
- ¿La similitud explica el vínculo o el vínculo produjo la similitud?

El problema fundamental: no independencia entre observaciones

En datos convencionales podemos imaginar observaciones $Y_1, Y_2, \dots, Y_n$ razonablemente independientes.

En una red observamos díadas Y_{ij} . Pero Y_{ij} e Y_{ik} comparten al actor i .

Por tanto:

$$\text{Cov}(Y_{ij}, Y_{ik}) \neq 0 \text{ en general}$$

Las díadas están estructuralmente relacionadas

Considere: $i \rightarrow j, i \rightarrow k, j \rightarrow k$

Los tres vínculos pueden relacionarse por:

- Características comunes de los actores;
- Reciprocidad;
- Cierre triádico;
- Pertenencia grupal;
- Oportunidades compartidas;
- Posiciones dentro de la red.

Una arista no constituye necesariamente una observación independiente.

El problema de usar inferencia convencional

Supongamos:

$$Y_{ij} = \beta_0 + \beta_1 X_{ij} + \varepsilon_{ij}$$

Podemos estimar β_1 . El problema aparece al calcular:

- Errores estándar;
- Intervalos de confianza;
- Valores p.

Si tratamos todas las díadas como independientes, podemos exagerar la cantidad de información realmente disponible.


Una alternativa: construir el mundo nulo

¿Qué valores de nuestra estadística aparecerían si elimináramos la relación de interés, manteniendo intactas las características que queremos conservar?

Datos observados

Actor	X: recursos	Y: influencia
A	1	2
B	2	3
C	3	4
D	4	7
E	5	9

$$T_{obs} = Cor(X, Y) = 0,98$$



Una permutación

Actor	X: recursos	Yperm
A	1	7
B	2	2
C	3	9
D	4	3
E	5	4


$$T_{perm} = Cor(X, Y_{perm}) = -0,27$$

Conservamos los mismos valores. Lo que cambia es quién queda emparejado con quién.

Repetir crea la distribución nula

Repetimos el barajado muchas veces y recalculamos la estadística:

$$T_1perm, T_2perm, \dots, T^Bperm$$




La distribución nula se obtiene de los datos y de la regla de permutación, no de una forma paramétrica asumida.

Valor p empírico

Para una prueba de cola derecha:

$$p_{emp} = [1 + \Sigma_{\beta} I(T_{\beta_{perm}} \geq T_{obs})] / (1 + B)$$

Ejemplo



$$p_{emp} = (1 + 19) / (1 + 999) = 0,02$$

El +1 evita obtener $p = 0$ por haber usado un número finito de permutaciones.

Pero en redes no podemos permutar cualquier cosa

En una matriz de red:

$$A = \begin{pmatrix} 0 & A_{12} & A_{13} & \cdots \\ A_{21} & 0 & A_{23} & \cdots \\ A_{31} & A_{32} & 0 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

las filas y columnas representan **los mismos actores**.

Permutar cada celda independientemente destruiría la estructura relacional.


■ Necesitamos una permutación compatible con los nodos.

Entonces...

En datos relacionales, las observaciones comparten nodos. La regla de permutación debe respetar esa estructura.


Permutar celdas

Puede destruir propiedades internas de la red.



Permutar etiquetas de nodos

Conserva la topología de la matriz, pero rompe su alineamiento con otra matriz.



Este problema lleva directamente a QAP: permutar nodos para construir el modelo nulo sin desarmar la red.

QAP

Quadratic Assignment Procedure


QAP compara dos matrices relacionales.

Por ejemplo: A_{ij} = existencia de vínculo, S_{ij} = similitud entre i y j

Pregunta: ¿los actores similares están conectados con mayor frecuencia?

Dos matrices, una pregunta

Red de vínculos A



Color = institución. La red muestra quién está conectado con quién.

A: vínculos

	A	B	C	D
A	0	1	1	0
B	1	0	1	0
C	1	1	0	1
D	0	0	1	0

vs.

S: misma institución

	A	B	C	D
A	1	1	0	0
B	1	1	0	0
C	0	0	1	1
D	0	0	1	1

Pregunta: ¿los 1 de A aparecen proporcionalmente más donde S también vale 1?

Primero calculamos la asociación observada

Cada díada se vuelve una observación

Díada	A	S
AB	1	1
AC	1	0
AD	0	0
BC	1	0
BD	0	0
CD	1	1

$$T_{\text{obs}} = \text{cor}(\text{vec}(A), \text{vec}(S))$$

interpretación

Si $T_{\text{obs}} > 0$, los vínculos aparecen proporcionalmente más entre actores similares.

Falta saber si esa correlación es significativa o no

La operación central: relabelar nodos, no mezclar celdas

S observada

	A	B	C	D
A	1	1	0	0
B	1	1	0	0
C	0	0	1	1
D	0	0	1	1

Orden de etiquetas: A, B, C, D

$\pi: A \rightarrow C$
 $B \rightarrow A$
 $C \rightarrow D$
 $D \rightarrow B$

Aplicar la misma permutación a filas y columnas

S permutada

	C	A	D	B
C	1	0	1	0
A	0	1	0	1
D	1	0	1	0
B	0	1	0	1

Nuevo orden de etiquetas: C, A, D, B

Intuición

- ✓ la estructura interna de S se preserva
- ✓ se preserva el patrón relacional asociado a las posiciones
- ✗ se rompe la correspondencia original entre A y S

Qué preserva QAP


La permutación simultánea de filas y columnas preserva:

- estructura interna de la matriz;
- número de vínculos;
- distribución asociada a cada nodo;
- dependencia dentro de la matriz permutada.

Pero rompe:

la **correspondencia entre A y S**


Distribución nula



¿ T_{obs} cae donde los valores son comunes o donde son raros?

Ese es nuestro mundo nulo.

Al establecer una asociación... ¿es ésta la correcta o puede ser otra?



En estos casos, una red transversal no revela el mecanismo generador del link

1. Selección



La similitud precede al vínculo.

2. Influencia



El vínculo precede a la convergencia.

3. Confusión




Una tercera causa produce ambas.

Observar $A_{ij} = 1$ y $X_i \approx X_j$ no permite identificar cuál historia ocurrió.

Cambiamos la pregunta

QAP / MRQAP

**¿Dos estructuras
relacionales
están asociadas?**




ERGM

**¿Qué configuraciones hacen más
probable
observar esta red?**

arista




cierre





La red completa es la variable aleatoria


Red observada y



Una realización entre muchas
redes posibles.



ERGM asigna mayor probabilidad a las redes que contienen las configuraciones favorecidas por los parámetros.



Sea $G=(V,E)$ una red. Sea $Y_{ij} = Y_{ji}$ una variable binaria que adquiere valor 1 si $e_{ij} \in E$. Entonces $Y = [Y_{ij}]$ es la *matriz aleatoria adyacente* de G . Tal que $y = [y_{ij}]$ es una realización particular de dicha matriz.

Un ERGM es la distribución de probabilidades conjunta de los elementos de $Y = y$:

$$P_{\theta}(Y = y) = \left(\frac{1}{k}\right) \exp\left\{\sum_H \theta_H g_H(y)\right\}$$


Donde: H es una “configuración” o set de posibles edges entre los vértices o nodos de G

$g_H(y) = \prod_{y_{ij} \in H} y_{ij}$, por lo tanto es 1 si la configuración H ocurre y 0 si no.


k es una constante de normalización: $k = k(\theta) = \exp\{\sum_H \theta_H g_H(y)\}$

Pensarlo como una regresión de configuraciones


$$\text{red} \sim \text{edges} + \text{mutual} + \text{nodematch} + \text{closure}$$




densidad basal



reciprocidad



homofilia



cierre triádico

Cada término representa una hipótesis sobre la formación de vínculos. Los parámetros indican qué configuraciones son favorecidas o desfavorecidas, condicionado a las demás.

Change statistics: la intuición operativa

¿Qué cambia si agregamos el vínculo i-j?

Antes

i

j

k



Después

i

j

k

El nuevo vínculo puede crear una arista, reciprocidad, homofilia o cerrar triángulos.

$$\log \frac{P(Y_{ij} = 1 \mid Y_{-ij})}{P(Y_{ij} = 0 \mid Y_{-ij})} = \theta^\top \Delta g_{ij}$$

Δg_{ij} pregunta:
¿cuántas configuraciones relevantes aparecen o desaparecen al cambiar este vínculo?

Esta es la forma más útil de interpretar un coeficiente ERGM.


Cuatro términos fundamentales

Término	Pregunta	Configuración
edges	¿qué tan costoso es formar un vínculo?	una arista
mutual	¿se favorece reciprocidad?	díada recíproca
nodematch	¿se favorece homofilia?	mismo atributo
closure	¿se favorece cierre triádico?	triángulo

Coeficiente positivo: esa configuración aparece más de lo que explica el resto del modelo.

Ejemplo: nodematch y homofilia

Más vínculos entre actores similares



$$\theta_{\text{nodematch}} > 0$$

Interpretación

Manteniendo constantes densidad, reciprocidad y cierre, conectar actores similares aumenta el log-odds condicional de vínculo.

Esto va más allá de observar simplemente que los vecinos se parecen.

El cierre no es simplemente “contar triángulos”


GWESP resume shared partners con retornos decrecientes.

0 socios compartidos




bajo

1 socio compartido



gran salto

5 socios compartidos



ganancia adicional menor

El primer socio compartido importa mucho más que pasar, por ejemplo, de 9 a 10. GWESP modela ese efecto decreciente.

Un ERGM combinado

$$Y \sim \text{edges} + \text{mutual} + \text{nodematch} + \text{GWESP}$$

edges

densidad

mutual


reciprocidad

nodematch

homofilia

GWESP


cierre



Cada coeficiente se interpreta condicionado a los demás mecanismos incluidos en el modelo.

ERGM no termina con los coeficientes

Un modelo puede estimarse correctamente y aun así representar mal la red.



Goodness of fit: ¿las redes simuladas reproducen grado, distancias, shared partners y otras propiedades relevantes?

En R se hace con el paquete statnet (compilado de varios paquetes)

Referencias: <https://statnet.org/trac>

Algoritmo:

1. Se estiman $\theta_1, \theta_2, \theta_3 \dots$ (varios métodos, maximum likelihood)
2. Se simulan redes con propiedades $\theta_1, \theta_2, \theta_3 \dots$
3. Se actualizan los valores de $\theta_1, \theta_2, \theta_3 \dots$ a partir de esas redes simuladas
4. Se repite 2... hasta lograr convergencia


En R se hace con el paquete statnet (compilado de varios paquetes)

Referencias: <https://statnet.org/trac>

Algoritmo:


1. Se estiman $\theta_1, \theta_2, \theta_3 \dots$ (varios métodos, maximum likelihood)
2. Se simulan redes con propiedades $\theta_1, \theta_2, \theta_3 \dots$
3. Se actualizan los valores de $\theta_1, \theta_2, \theta_3 \dots$ a partir de esas redes simuladas
4. Se repite 2... hasta lograr convergencia

Matrimonios



20 links de 120 posibles en teoría

Negocios



=====
Summary of model fit
=====

Formula: flomarriage ~ edges

Iterations: 5 out of 20

Monte Carlo MLE Results:

	Estimate	Std. Error	MCMC %	p-value
edges	-1.6094	0.2449	0	<1e-04 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Null Deviance: 166.4 on 120 degrees of freedom

Residual Deviance: 108.1 on 119 degrees of freedom

AIC: 110.1 BIC: 112.9 (Smaller is better.)

θ_m

Odd ratio = $-1,609 * 1$ (cambio de 0 a 1)

$$\Pr(l_{ij} = 1) = \frac{e^{-1,609}}{1 + e^{-1,609}} = 0,1667$$

... que es justamente lo que esperábamos porque:

20 links reales / 120 posibles = 0,1667

=====

Summary of model fit

=====

Formula: flomarriage ~ edges + triangle

Iterations: 2 out of 20

Monte Carlo MLE Results:

	Estimate	Std. Error	MCMC	% p-value
edges	-1.6603	0.3556	0	<1e-04 ***
triangle	0.1300	0.5944	0	0.827

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Null Deviance: 166.4 on 120 degrees of freedom

Residual Deviance: 108.1 on 118 degrees of freedom

AIC: 112.1 BIC: 117.6 (Smaller is better.)

Odd ratio = $-1,609 * 1 + 0,13 * T$

Si $T = 0 \rightarrow$ odd ratio: -1,609

Si $T = 1 \rightarrow$ odd ratio: -

$1,609 + 0,13 = -1,47$

$$\Pr(l_{ij} = 1 | T = 1) = 0,185$$

... y sube en aprox.2 pts por
tríada

```

=====
Summary of model fit
=====
Formula: flomarriage ~ edges + triangle + nodecov("wealth")
Iterations: 2 out of 20
Monte Carlo MLE Results:
      Estimate Std. Error MCMC % p-value
edges      -2.580037  0.536265    0 <1e-04 ***
triangle    -0.116286  0.620783    0  0.8517
nodecov.wealth 0.010886  0.005018    0  0.0321 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Null Deviance: 166.4 on 120 degrees of freedom
Residual Deviance: 103.1 on 117 degrees of freedom
AIC: 109.1   BIC: 117.4   (Smaller is better.)

```

Como *wealth* son atributos de nodos, se consideran ambas riquezas al ver la probabilidad de cada link ij .

Wealth:

```

[1] 10 36 55 44 20 32  8 42 103
48 49  3 27 10 146 48

```


Ej: link con una tríada entre familias con riqueza 10 y 146:
 $-2,58 - 0,11 + 0,01 \cdot (10 + 146) = -1,13$

En prob: 0,24

Este modelo sugiere mayor probabilidad de un link a mayor riqueza de ambas familias


¿el modelo cómo
se ajusta a los
datos?

A partir del
modelo se
simulan redes y se
calculan las
mismas variables
del modelo




Y también otras que son descriptores básicos de la red, pero no estaban en el modelo:

Distribución de grado




Y también otras que son descriptores básicos de la red, pero no estaban en el modelo:

Geodésicas



Y también otras que
son descriptores
básicos de la red, pero
no estaban en el
modelo:

Vecinos compartidos





Para poder hacer GOF fue necesario hacer simulaciones.


Stored network statistics:

	edges	triangle	nodecov.wealth
[1,]	23	5	2374
[2,]	20	4	1961
[3,]	22	4	2585
[4,]	19	0	2092
[5,]	18	0	1494
[6,]	20	5	2378
[7,]	21	2	2308
[8,]	19	2	1661


...




Sample statistics



Un grafo aleatorio ajustado a los datos de interlocking (personas)




Un grafo aleatorio ajustado a los datos de interlocking (personas)



Un grafo aleatorio ajustado a los datos de interlocking (personas)

Goodness-of-fit diagnostics



Dos formas distintas de inferencia

	QAP / MRQAP	ERGM
Pregunta	¿dos estructuras están asociadas?	¿qué configuraciones favorecen esta red?
Objeto	matrices relacionadas	red completa
Inferencia	permutaciones	modelo probabilístico + simulación
Dependencia endógena	limitada	explícita
Ejemplo	similitud $\leftrightarrow$ vínculo	homofilia + reciprocidad + cierre

Ambos reconocen dependencia relacional, pero construyen objetos inferenciales diferentes.

Referencias

Krackhardt, D. (1988). "Predicting with Networks: Nonparametric Multiple Regression Analysis of Dyadic Data." *Social Networks*, 10(4), 359-381.

Robins, G., Pattison, P., Kalish, Y., & Lusher, D. (2007). "An Introduction to Exponential Random Graph Models for Social Networks." *Social Networks*, 29(2), 173-191.

Lusher, D., Koskinen, J., & Robins, G. (Eds.). (2013). *Exponential Random Graph Models for Social Networks: Theory, Methods, and Applications*. Cambridge University Press.

Cranmer, S. J., Desmarais, B. A., & Morgan, J. W. (2021). *Inferential Network Analysis*. Cambridge University Press.