


Redes de variables y dependencia condicional

De asociaciones observadas a modelos gráficos, regularización, estabilidad e interpretación.



PREGUNTA GUÍA

¿Qué relaciones entre un par (i,j) permanecen cuando consideramos simultáneamente el resto de las relaciones en la red, $\sim (i,j)$?

síntomas

actitudes

creencias

ítems

asociación marginal $\rightarrow$ dependencia condicional $\rightarrow$ estructura


Una red puede representar actores, pero también variables

Red de actores

nodo = persona / organización

arista = relación observada

pregunta = ¿quién se relaciona con quién?




Red de variables

nodo = variable observada


arista = relación estadística condicionada

pregunta = ¿qué variables permanecen asociadas?



Una red de correlaciones puede quedar casi completamente conectada

Cinco variables generan diez pares posibles.




10

correlaciones
posibles

¿Cada correlación representa una relación estructural propia?

Dos variables pueden covariar a través de una tercera



$$\text{Cor}(A,C) > 0$$

La asociación A–C puede estar transmitida por B.

La pregunta cambia cuando incorporamos el resto del sistema

Asociación marginal

$$\text{Cor}(X_i, X_j)$$

¿se mueven juntas?



Asociación condicional

$$X_i \leftrightarrow X_j \mid X_{\sim(ij)}$$

¿la relación permanece dado el resto?


Una ausencia de información adicional puede escribirse formalmente

$$X_i \perp X_j \mid X_{-(ij)}$$

Conocido el resto del sistema, X_i deja de aportar información sobre X_j .


La estructura relevante será una estructura de dependencias e independencias condicionales.

Condicionar puede eliminar una asociación aparente



La arista A–C pierde necesidad estadística cuando conocemos B.

Los grafos causales muestran por qué las independencias condicionales son informativas



$$A \rightarrow B \rightarrow C \text{ implica } A \perp C \mid B$$

Las independencias condicionales restringen qué estructuras son compatibles con los datos.


La red codifica la estructura condicional del sistema

$$G = (V, E)$$

V = variables aleatorias observadas

E = dependencias condicionales por pares

$$(i, j) \notin E \iff X_i \perp X_j \mid X_{\sim(ij)}$$




Una correlación pregunta si dos variables se mueven juntas.

Un PMRF pregunta si todavía están relacionadas después de considerar todo el resto del sistema.

INTERPRETACIÓN

Una arista representa una asociación que persiste dado el conjunto de variables incluidas



La arista delimita dependencia condicional. La interpretación sustantiva requiere información adicional.

La red es desconocida y debe estimarse a partir de una muestra


Matriz de datos X

X_1	X_2	X_3	...	X_p
1	0	1	...	0
0	1	1	...	1
1	1	0	...	1
$\vdots$	$\vdots$	$\vdots$		$\vdots$


Objetos a estimar

- presencia de aristas
- magnitud de relaciones
- incertidumbre muestral
- estabilidad de la estructura

Red de correlaciones parciales



Red de correlaciones



Ejemplo en R

La parametrización del grafo depende del tipo de variable de interés

Tipo de datos	Modelo	Interpretación del edge
Binarios	Ising	Interacción condicional
Continuos	Gaussian Graphical Model	Correlación parcial
Mixtos	Mixed Graphical Model	Asociación condicional según dominio

La lógica es siempre la misma entre modelos: representar dependencias condicionales mediante un grafo.


PRIMER CASO

Variables binarias

$$X_i \in \{-1, +1\}$$



El modelo de Ising describe unidades binarias que interactúan localmente



En psicometría, las unidades pueden ser síntomas, respuestas o creencias con dos estados.

La probabilidad conjunta combina propensiones individuales e interacciones

$$P(X=x) = (1/Z) \exp[\sum_i \tau_i x_i + \sum_{i<j} \omega_{ij} x_i x_j]$$

τ_i

propensión del
nodo


ω_{ij}

interacción entre
nodos

Z


normalización

El parámetro τ_i inclina el nodo hacia uno de sus dos estados



El parámetro ω_{ij} determina si dos variables conservan una relación condicional

$$\omega_{ij} < 0$$



favorece estados
discordantes

$$\omega_{ij} = 0$$



ausencia de edge
independencia condicional

$$\omega_{ij} > 0$$



favorece estados
concordantes

El Ising puede escribirse como una regresión logística para cada nodo

$$\log [P(X_i=1 \mid X_{-i}) / P(X_i=-1 \mid X_{-i})] = 2\tau_i + 2\sum_{j \neq i} \omega_{ij}X_j$$


El estado de X_i depende de su propensión y de los estados de las variables conectadas.

La muestra de respuestas se transforma en una red de variables

$n \times p$


filas = individuos
columnas = ítems

	A	B	C	D
1	1	0	1	1
2	0	1	1	0
3	1	1	0	1
4	0	0	1	1



ω_{ij}

Los síntomas pueden formar un sistema de variables que se refuerzan mutuamente




El patrón conjunto puede interpretarse como interacción entre variables observadas.


DOS REPRESENTACIONES

**La misma covariación puede admitir explicaciones sustantivas diferentes
... y esto conecta con el debate entre frequentistas y bayesianos**

Variable latente




Sistema de interacción



La distribución observada puede ser compatible con ambas familias bajo determinadas parametrizaciones.

Del dato binario a una estructura condicional



Siguiente paso: variables continuas, estimación sparse e incertidumbre.

SEGUNDO CASO

Variables continuas

$$X \sim N_p(\mu, \Sigma)$$




MATRIZ DE COVARIANZAS

Las asociaciones marginales siguen mezclando relaciones directas e indirectas

Σ covarianzas

	X_1	X_2	X_3
X_1	σ_{11}	σ_{12}	σ_{13}
X_2	σ_{21}	σ_{22}	σ_{23}
X_3	σ_{31}	σ_{32}	σ_{33}



¿Qué queda después de controlar simultáneamente por las demás variables?

Invertir Σ permite recuperar la estructura condicional bajo normalidad multivariada

$$\Omega = \Sigma^{-1}$$

$\omega_{ij} = 0$ independencia condicional


$\omega_{ij} \neq 0$ arista potencial en el GGM



Gaussian Graphical Model


Los pesos del GGM pueden expresarse como asociaciones condicionadas al resto

$$\rho_{ij} | \text{resto} = - \omega_{ij} / \sqrt{\omega_{ii} \omega_{jj}}$$



Interpretación: asociación entre X_i y X_j después de considerar simultáneamente las demás variables.

De la matriz de datos a la red condicional



Cada etapa añade una decisión estadística que puede afectar la estructura final.

El número de relaciones posibles crece rápidamente con p

$$\text{posibles aristas} = p(p-1) / 2$$

p = 10

45

p = 20

190

p = 50


1225

p = 100

4950

Con muestras limitadas, muchas asociaciones pequeñas pueden reflejar variación muestral.


La estimación busca equilibrio entre ajuste y parsimonia



Regularizar desplaza parte de los parámetros hacia cero.


LASSO puede llevar algunos parámetros exactamente a cero

$$\text{penalización} = \lambda \sum_i |\omega_{ij}|$$




GLASSO estima una matriz de precisión sparse

$$\Omega = \arg \max_{\Omega} \{ \log |\Omega| - \text{tr}(S\Omega) - \lambda ||\Omega||_1 \}$$




La misma muestra puede producir redes con distinta densidad


λ bajo



λ intermedio



λ alto



Más penalización $\rightarrow$ más coeficientes exactamente en cero $\rightarrow$ red más sparse.

Las bases sociales suelen combinar dominios de variables



Mixed Graphical Model

Cada relación se parametriza respetando el dominio de las variables involucradas.

Tres especificaciones, una misma pregunta estructural

Binarios

Ising

ω_{ij}

Continuos

GGM

$\rho_{ij} \cdot \text{resto}$

Mixtos

MGM

parámetro condicional

Pregunta común: ¿qué variables conservan una relación una vez considerado el resto?


Una vez estimada la red

$$G = (V, E)$$



La fuerza resume cuánta asociación condicional concentra un nodo


$$\text{Strength}_i = \sum_j |w_{ij}|$$



Interpretación: integración del nodo en el sistema de asociaciones condicionadas.


COMUNIDADES

La estructura local puede revelar grupos densamente conectados de variables



La lógica de detección de comunidades reutiliza herramientas vistas para redes de actores.


EGA utiliza comunidades de una red para estudiar dimensionalidad




EGA convierte la partición de ítems en una estimación del número y composición de dimensiones.

Ambos estudian dimensionalidad desde representaciones estadísticas distintas


Análisis factorial



EGA



Una distribución observada puede admitir una lectura latente y una lectura de red



**misma distribución sobre variables observadas
bajo determinadas parametrizaciones**

La red estimada cambia con la muestra

Aristas

pesos y presencia

Centralidad

ranking y
magnitud

Comunidades


partición

Densidad


número de
relaciones

Una segunda muestra puede producir una estructura distinta aun cuando el proceso subyacente sea el mismo.

Re-muestrear individuos permite evaluar precisión de los pesos




El ranking de nodos también debe resistir variación muestral




Dos visualizaciones diferentes requieren una prueba explícita de diferencia

Grupo A



Grupo B



Comparar estructura · edges ·
fuerza global

La dependencia condicional y el efecto de intervención son objetos distintos

Red observacional



$$X_1 \leftrightarrow X_2 \mid \text{resto}$$

Pregunta de intervención




$$\text{do}(X_1=x) \rightarrow \Delta X_2 ?$$

Temporalidad, diseño y supuestos causales determinan qué inferencias de intervención son justificables.

Una causa común y una interacción directa pueden inducir asociaciones similares

Causa común



Interacción



La diferencia sustantiva aparece cuando preguntamos qué ocurre bajo intervención.

Una red de variables entrega información estructural; afirmaciones adicionales requieren evidencia adicional


La red permite estudiar

- dependencias condicionales
- peso de asociaciones
- comunidades
- centralidad
- estabilidad muestral

Requiere evidencia adicional

- dirección causal
- mecanismo de transmisión
- efecto de intervención
- propagación temporal

EN RESUMEN



De describir asociaciones a justificar qué estructura creemos haber identificado.

Referencias

Epskamp, S., Maris, G., Waldorp, L. J., & Borsboom, D. (2018). Network psychometrics. In P. Irwing, T. Booth, & D. J. Hughes (Eds.), *The Wiley handbook of psychometric testing*. Wiley. <https://doi.org/10.1002/9781118489772.ch30>

Epskamp, S., Borsboom, D., & Fried, E. I. (2018). Estimating psychological networks and their accuracy: A tutorial paper. *Behavior Research Methods*, 50(1), 195–212. <https://doi.org/10.3758/s13428-017-0862-1>

Friedman, J., Hastie, T., & Tibshirani, R. (2008). Sparse inverse covariance estimation with the graphical lasso. *Biostatistics*, 9(3), 432–441. <https://doi.org/10.1093/biostatistics/kxm045>

Golino, H. F., & Epskamp, S. (2017). Exploratory graph analysis: A new approach for estimating the number of dimensions in psychological research. *PLOS ONE*, 12(6), e0174035. <https://doi.org/10.1371/journal.pone.0174035>

Haslbeck, J. M. B., & Waldorp, L. J. (2020). mgm: Estimating time-varying mixed graphical models in high-dimensional data. *Journal of Statistical Software*, 93(8), 1–46. <https://doi.org/10.18637/jss.v093.i08>

Pearl, J. (2000). *Causality: Models, reasoning, and inference*. Cambridge University Press.

van Borkulo, C. D., van Bork, R., Boschloo, L., Kossakowski, J. J., Tio, P., Schoevers, R. A., Borsboom, D., & Waldorp, L. J. (2023). Comparing network structures on three aspects: A permutation test. *Psychological Methods*, 28(6), 1273–1285. <https://doi.org/10.1037/met0000476>